

Hasil dan Analisis Performa Model

1. Hasil Eksperimen

Pada penelitian ini dilakukan pelatihan model Tiny GPT menggunakan corpus yang berisi lebih dari 2000 kata dengan tiga pendekatan tokenisasi, yaitu Character, BPE (Byte Pair Encoding), dan Unigram. Setiap model dilatih menggunakan konfigurasi yang sama, yaitu embedding dimension 32, jumlah attention head 2, jumlah transformer layer 2, learning rate 0,001, dan 1500 epoch.

Tokenizer	Vocab Size	Total Token	Loss Awal	Loss Akhir
Character	46	16.934	4,0777	1,8189
BPE	100	10.078	4,7882	2,4075
Unigram	100	10.697	4,8712	2,4507

2. Hasil Generasi Teks

1) Character Tokenizer

machine learning jang mentidip idagpa GLPat celatat prapat swara ami
taisi memberati...

2) BPE Tokenizer

machine learning penula belanalisis siderik kaluat. Mas. Perah. Jika kaca...

3) Unigram Tokenizer

machine learning lobeh jantu, hada kalimis dapat dipasdeksi modelan
jacosi ini...

3. Analisis Performa

Berdasarkan hasil eksperimen, seluruh model menunjukkan penurunan nilai loss selama proses training. Hal ini menunjukkan bahwa model berhasil mempelajari pola yang terdapat pada corpus yang digunakan.

- 1) Pendekatan Character menghasilkan nilai loss akhir paling rendah yaitu 1,8189. Hal ini menunjukkan bahwa model mampu mengenali pola karakter dengan cukup baik. Namun hasil generasi teks masih sulit dipahami karena model hanya mempelajari hubungan antar karakter sehingga banyak menghasilkan kata yang tidak utuh atau tidak memiliki makna yang jelas.

- 2) Pendekatan BPE menghasilkan nilai loss akhir sebesar 2,4075. Walaupun nilai loss lebih tinggi dibandingkan Character, hasil teks yang dihasilkan lebih mudah dikenali karena model mempelajari potongan kata (subword) yang sering muncul dalam corpus. Beberapa istilah seperti *machine learning*, *token*, *model*, dan *corpus* masih dapat dikenali pada hasil generasi. Oleh karena itu, pendekatan BPE menghasilkan keseimbangan yang lebih baik antara ukuran vocabulary, jumlah token, dan kualitas teks yang dihasilkan.
- 3) Pendekatan Unigram menghasilkan nilai loss akhir sebesar 2,4507. Hasil yang diperoleh cukup baik, namun kualitas teks yang dihasilkan masih berada di bawah BPE. Beberapa kata yang muncul masih mengalami distorsi sehingga kalimat yang dihasilkan belum sepenuhnya mudah dipahami.

4. Perbandingan Antar Pendekatan

Dari ketiga pendekatan tokenisasi yang digunakan, Character menghasilkan nilai loss terendah. Akan tetapi, kualitas teks yang dihasilkan belum menjadi yang terbaik. BPE menghasilkan teks yang relatif lebih mudah dipahami walaupun nilai loss sedikit lebih tinggi. Sementara itu, Unigram memberikan hasil yang cukup baik tetapi belum mampu melampaui performa BPE. Berdasarkan hasil tersebut, pendekatan BPE dapat dianggap sebagai metode tokenisasi yang paling sesuai untuk corpus yang digunakan karena mampu memberikan keseimbangan antara efisiensi tokenisasi dan kualitas teks yang dihasilkan.

5. Perbedaan Hasil Antar Run

Pada saat eksperimen dilakukan beberapa kali, nilai loss dan hasil generasi teks tidak selalu sama meskipun menggunakan corpus dan konfigurasi model yang identik. Hal ini merupakan kondisi yang normal dalam proses pelatihan neural network. Perbedaan hasil tersebut disebabkan oleh proses inisialisasi bobot model yang dilakukan secara acak, pengambilan batch data training yang berbeda pada setiap iterasi, serta proses sampling token saat model menghasilkan teks baru. Akibatnya, model dapat menghasilkan nilai loss dan teks generasi yang sedikit berbeda pada setiap proses training. Meskipun demikian, pola hasil yang diperoleh tetap konsisten. Pada setiap percobaan,

nilai loss terus menurun selama training, tokenisasi Character menghasilkan loss paling rendah, sedangkan tokenisasi BPE menghasilkan kualitas teks yang lebih baik dibandingkan pendekatan lainnya. Oleh karena itu, perbedaan kecil antar run tidak memengaruhi kesimpulan utama dari penelitian ini.

6. Kesimpulan

Berdasarkan hasil eksperimen yang telah dilakukan, model Tiny GPT berhasil dilatih menggunakan corpus yang dibuat sendiri dan mampu menghasilkan teks baru berdasarkan pola yang dipelajari. Ketiga pendekatan tokenisasi menunjukkan performa yang berbeda. Pendekatan Character menghasilkan loss terendah, sedangkan pendekatan BPE menghasilkan keseimbangan terbaik antara ukuran vocabulary, jumlah token, dan kualitas teks yang dihasilkan. Dengan demikian, BPE dipilih sebagai pendekatan tokenisasi yang paling sesuai pada eksperimen Tiny GPT ini.

7. Link Repository

<https://github.com/tanzz15/TinyGPT-MiniCorpus>